Agente de voz de cobranza NSF

Backend: objetivo, stack tecnológico y funciones

Versión 3, del 10 de noviembre de 2026. Repositorio: github.com/CristopherBuitrago/agent_caller (rama main). Fuente de cada decisión: README.md del repositorio.

Estado

Las funciones 1 a 5 y la 7 están construidas y probadas (166 pruebas pasan). La Función 6 (pago con tarjeta) está bloqueada hasta elegir el proveedor del IVR PCI. El paso 8 (conversación con Claude) está en construcción: diseño aprobado, código a medias.

Cómo leer la columna Origen

- **Jefe:** la respuesta vino del jefe.
- **Desarrollador:** la respuesta o la aprobación vino del desarrollador.

1. Por qué existe este backend

Un modelo de IA conversa bien, pero no es confiable para aplicar reglas de negocio: puede equivocarse en un monto, saltarse un paso o ceder ante un deudor que pide un descuento. En cobranza esos errores son caros y, en algunos casos, ilegales (FDCPA, Reg F, PCI).

Por eso se separan las responsabilidades:

- **La IA solo conversa** y pide acciones (herramientas).
- **El backend decide y valida todo**: quién es el deudor, si se verificó, qué oferta toca, que los pagos sumen el saldo completo (nunca hay descuentos), las fechas permitidas, el cambio de estado a PTP, las disputas y el "no llamar". Si la IA pide algo prohibido, el backend lo rechaza con el motivo.
- **Todo queda registrado** en la base: llamada, consentimiento, intentos de verificación, acuerdo, cuotas y resumen.
- **Nada depende de un proveedor**: la base de datos, el modelo de IA y la telefonía están detrás de interfaces (arquitectura hexagonal). Cuando llegue la base real o se cambie de proveedor, solo se cambia la implementación en infrastructure/config/container.py.

2. Objetivo

Atender llamadas en inglés de deudores con un pago rebotado (NSF) en EE. UU., verificar su identidad, negociar el pago del saldo completo y dejar la cuenta en PTP (Promise To Pay). El trabajo del agente termina en PTP: las llamadas de recordatorio las hace un cobrador.

- **Entrantes:** el deudor llama, normalmente porque recibió un mensaje de que su pago rebotó. Se le busca por el número desde el que llama.
- **Salientes:** solo NSF, después de que el job de pagos entrega su resultado.
- **Volumen previsto:** 2.000 llamadas diarias.
- **Fuera del alcance:** cualquier estado distinto de NSF (pasa a una persona), RCC y las llamadas de recordatorio.

3. Stack tecnológico

En uso (construido y probado)

Componente	Tecnología	Por qué
Lenguaje	Python 3.12	Ecosistema de IA y voz (SDK de Anthropic, Pipecat).
Arquitectura	Hexagonal: domain / application / infrastructure	Las reglas no dependen de la base ni del proveedor. Una prueba impide que domain o application importen infraestructura.
Base de datos	PostgreSQL 16 (provisional)	Detrás de interfaces (DebtorRepository, CallRepository...) hasta conocer la base real y su EER.
Acceso a datos	psycopg 3 + psycopg_pool	SQL directo y pool de conexiones.
Teléfonos	phonenumbers	Normaliza números y deduce la zona horaria del código de área.
Datos sensibles	HMAC-SHA256	SSN y fecha de nacimiento se guardan como hash; la IA nunca los ve.
IA: resumen y conversación	Claude Haiku 5.5, con Claude Sonnet 5.5 de respaldo	Haiku es el más rápido y barato; si rechaza o falla, responde Sonnet.
Pruebas	pytest	Unitarias sin base, integración contra PostgreSQL y prueba de arquitectura.
Entorno	Docker Compose	Base y pruebas con un solo comando.

Los proveedores externos que necesita el agente (cuáles ya están elegidos y por qué hacen falta) están en la sección 6.

Comandos

Pruebas: `cd backend && docker compose run --rm --build app`
Base: `docker compose up -d` (puerto 5433). Recrear: `docker compose down -v && docker compose up -d`

4. Listado de funciones

Todavía no hay endpoints HTTP, a propósito. Antes de conectar telefonía, el primer paso es una prueba por chat: una persona escribe simulando ser el deudor y Claude responde como el agente. Para eso no hace falta HTTP.

Por eso hoy los puntos de entrada del backend son los **casos de uso**: clases con un método `execute` que reciben datos simples y devuelven un resultado. Los llaman el chat de prueba y, más adelante, el servidor de voz y los endpoints HTTP (job de NSF, telefonía e IVR), que se crearán con la capa de voz.

En el detalle de cada función, la entrada y la salida se muestran en **JSON**, como las recibiría y devolvería cada endpoint. Los ejemplos usan el caso de prueba TEST-001 (Jane Carter, cuenta ACC-T001, saldo de USD 485). Los montos van en centavos y las fechas en formato AAAA-MM-DD.

#	Caso de uso	Qué hace	Estado
1	FindDebtorsByPhone	Busca deudores por el teléfono desde el que llaman (entrante).	Hecho
1	GetDebtorByAccount	Trae al deudor dueño de la cuenta del job (saliente).	Hecho
2	VerifyIdentity	Verifica nombre, últimos 4 del SSN y fecha de nacimiento.	Hecho
3	StartCall	Registra el inicio de la llamada.	Hecho
3	RecordRecordingConsent	Guarda si el deudor aceptó la grabación.	Hecho
3	EndCall	Cierra la llamada con su resultado y el resumen hecho por IA.	Hecho
4	ProposeArrangement	Arma la oferta N: 1 = todo de una, 2 = 2 cuotas, 3 = 3 cuotas...	Hecho
4	ProposeNextOffer	Elige la siguiente oferta que toca y la registra.	Nuevo, sin probar
4	ProposePartialPayment	Arma un pago parcial con el monto que dijo el deudor.	Cambiado, sin probar
4	RecordOfferResponse	Registra si el deudor acepta o rechaza una propuesta.	Nuevo, sin probar
4	CreateArrangement	Guarda el acuerdo y pasa la cuenta a PTP.	Hecho
5	RecordHardshipAssessment	Guarda las respuestas de las Hardship Questions.	Hecho
6	(IVR PCI)	Transferir al pago con tarjeta y registrar el resultado.	Bloqueado
7	RecordDispute	Marca la cuenta en disputa y cierra la llamada.	Hecho
7	MarkDoNotCall	Marca al deudor como "no llamar" y cierra la llamada.	Hecho
8	Conversación con Claude	Conecta todo lo anterior en el chat de prueba (luego, voz).	En construcción

5. Detalle por función

Base: modelo de datos

Qué hace: Tablas debtors (la persona), accounts (cada deuda), calls (cada llamada), payment_arrangements y scheduled_payments (el acuerdo y sus pagos), payment_results (respuesta del IVR) y hardship_assessments. Montos en centavos. Datos simulados: 509 deudores, 747 cuentas y 9 casos de prueba TEST-xxx.

Por qué: Un deudor puede tener varias deudas, y cada llamada y acuerdo debe quedar auditado.

El diagrama EER del modelo actual se entrega aparte.

Preguntas y respuestas

Pregunta	Respuesta	Origen
¿Qué estados se cobran?	Solo NSF. Cualquier otro, incluidos first_attempt a fourth_attempt, pasa a una persona.	Jefe
¿Un deudor puede tener varias deudas?	Sí, con el mismo acreedor o con otros.	Jefe
¿Hay datos del NSF?	Sí.	Jefe
¿Hay estado o dirección del deudor?	Puede faltar; después de fourth_attempt se usa Skip Tracing.	Jefe
¿Los estados de intento van en el mismo campo que NSF?	Sí, en accounts.status.	Desarrollador
¿Hay nombres de campos fijos?	Sí, vendrán en el EER. Mientras tanto se usa este modelo.	Jefe

Supuestos vigentes

- El NSF puede venir de ACH, cheque o tarjeta (el modelo acepta los tres).

Pendiente

- Diagrama EER y base de datos real.
- Si el resultado de la llamada se inserta como fila nueva o actualiza un registro existente.

Función 1: consultar deudor

Qué hace: Devuelve al deudor con sus cuentas: nombre, cuenta enmascarada, acreedor, saldo, estado, datos del NSF, disputa y "no llamar". Nunca devuelve SSN ni fecha de nacimiento.

Por qué: Es el primer paso de toda llamada, y define qué cuentas puede cobrar el agente.

Casos de uso

FindDebtorsByPhone	Entrante: busca por el teléfono principal o secundario. Devuelve una lista porque un teléfono puede ser compartido; vacía si no hay o el número no es válido.
Entrada (JSON)	**Salida (JSON)**

```
{
  "raw_phone": "(305) 555-0001"
}
```

```
[
  {
    "id": "2b9d7e41-8c3a-4f5e-a1b2-c3d4e5f60718",
    "external_id": "TEST-001",
    "first_name": "Jane",
    "last_name": "Carter",
    "phone_primary": "+13055550001",
    "us_state": "FL",
    "timezone": "America/New_York",
    "timezone_inferred": false,
    "do_not_call": false,
    "accounts": [
      {
        "id": "5a6b7c8d-9e0f-4a1b-8c2d-3e4f5a6b7c8d",
        "external_id": "ACC-T001",
        "creditor_name": "Lakeside Auto Finance",
        "account_number_masked": "****4821",
        "current_balance_cents": 48500,
        "status": "NSF",
        "payment_method": "ACH",
        "nsf_amount_cents": 45000,
        "nsf_fee_cents": 3500,
        "nsf_date": "2026-10-10",
        "nsf_return_code": "R01",
        "is_disputed": false
      }
    ]
  }
]
```

GetDebtorByAccount	Saliente: el deudor dueño de la cuenta del job. Si no existe, devuelve null.

Entrada (JSON)

```
{
  "account_external_id": "ACC-T001"
}
```

Salida (JSON)

```
{
  "id": "2b9d7e41-8c3a-4f5e-a1b2-c3d4e5f60718",
  "external_id": "TEST-001",
  "first_name": "Jane",
  "last_name": "Carter",
  "phone_primary": "+13055550001",
  "us_state": "FL",
  "timezone": "America/New_York",
  "timezone_inferred": false,
  "do_not_call": false,
  "accounts": [
    {
      "id": "5a6b7c8d-9e0f-4a1b-8c2d-3e4f5a6b7c8d",
      "external_id": "ACC-T001",
      "creditor_name": "Lakeside Auto Finance",
      "account_number_masked": "****4821",
      "current_balance_cents": 48500,
      "status": "NSF",
      "payment_method": "ACH",
      "nsf_amount_cents": 45000,
      "nsf_fee_cents": 3500,
      "nsf_date": "2026-10-10",
      "nsf_return_code": "R01",
      "is_disputed": false
    }
  ]
}
```

Preguntas y respuestas

Pregunta	Respuesta	Origen
¿Cómo se identifica a quien llama?	"agente recibe num y busca": por el número desde el que llama.	Jefe
Saliente sin ubicación	Se cobra normal y la zona horaria se deduce del código de área.	Desarrollador
¿Cómo entrega el job sus resultados?	Por definir.	Jefe

Pendiente

- Cómo entrega el job sus resultados (no impide avanzar: hoy se busca por ID de cuenta).

Función 2: verificar identidad

Qué hace: Compara lo que dijo el deudor con lo guardado (en hash). Nunca dice qué dato falló.

Por qué: La ley prohíbe hablar de la deuda con alguien que no sea el deudor.

Casos de uso

VerifyIdentity	Verifica y cuenta el intento en calls.verification_attempts. outcome puede ser verified, name_retry (pedir deletrear el apellido), failed, max_attempts_reached o locked.
Entrada (JSON)	**Salida (JSON)**
`{ "call_id": "7c1e4b2a-5d3f-4e8a-9b61-0f2d3c4a5b6e", "debtor_id": "2b9d7e41-8c3a-4f5e-a1b2-c3d4e5f60718", "full_name": "Jane Carter", "ssn_last4": "1234", "dob": "1985-03-14", "name_was_spelled": false }`	`{ "outcome": "verified" }`

Preguntas y respuestas

Pregunta	Respuesta	Origen
¿Qué se verifica?	Nombre completo + últimos 4 del SSN + fecha de nacimiento.	Desarrollador
¿Dónde se cuentan los intentos?	En un campo nuevo, verification_attempts; el de estado cuenta los intentos de cobro.	Desarrollador
¿Bloquear tras 5 fallos en 24 h?	Sí: se bloquea y pasa a una persona.	Desarrollador
¿Pedir deletrear el apellido antes de contar un fallo?	Sí.	Desarrollador

Supuestos vigentes

- Máximo 2 fallos por llamada; después se cierra sin revelar la deuda.

Función 3: registrar la llamada y resumen

Qué hace: Crea la llamada, guarda el consentimiento de grabación y la cierra con su resultado y un resumen en inglés hecho por IA.

Por qué: Toda llamada se graba y queda registrada; el resumen le ahorra al equipo leer la transcripción.

Casos de uso

StartCall	Crea la llamada. En salientes (outbound) account_external_id es obligatorio; en entrantes va null.
Entrada (JSON)	**Salida (JSON)**
`{ "direction": "inbound", "caller_phone": "+13055550001", "account_external_id": null }`	`{ "call_id": "7c1e4b2a-5d3f-4e8a-9b61-0f2d3c4a5b6e" }`

RecordRecordingConsent	Guarda el consentimiento. Si accepted es false, la llamada solo se puede cerrar como recording_refused.
Entrada (JSON)	**Salida (JSON)**

{
"call_id": "7c1e4b2a-5d3f-4e8a-9b61-0f2d3c4a5b6e",
"accepted": true
}
	{
	"can_continue": true
	}

EndCall	Cierra la llamada y genera el resumen. Si la IA falla, se cierra igual y summary va null.
Entrada (JSON)	**Salida (JSON)**

{
"call_id": "7c1e4b2a-5d3f-4e8a-9b61-0f2d3c4a5b6e",
"outcome": "arrangement_made",
"transcript": "Agent: ... Debtor: ..."
}
	{
	"summary": "Jane Carter was verified and agreed to pay the $485.00 balance in 2 monthly payments of $242.50 starting November 13."
	}

Preguntas y respuestas

Pregunta	Respuesta	Origen
¿Aviso de grabación?	Sí, al inicio de cada llamada.	Desarrollador
¿Y si el deudor no acepta?	"Por ley se tiene que grabar": se cierra como recording_refused sin hablar de la deuda.	Desarrollador
¿La IA hace el resumen?	Sí.	Desarrollador
¿Con qué modelo?	Claude Haiku 5.5; Claude Sonnet 5.5 de respaldo.	Desarrollador
¿En qué idioma va el resumen?	Inglés: todos hablan inglés y el servicio es para EE. UU.	Desarrollador

Supuestos vigentes

- La grabación es obligatoria. Falta saber qué ley o política lo exige: no se conoce una ley federal que lo haga.

Pendiente

- Probar el resumen con la API real (falta ANTHROPIC_API_KEY).

Función 4: negociar el acuerdo

Qué hace: Arma las ofertas en orden, valida cada propuesta y guarda el acuerdo aceptado. Cuotas iguales y mensuales; los pagos siempre suman el saldo completo.

Por qué: La negociación es donde más daño hace un error de la IA (montos, descuentos, plazos). Aquí el código decide todo y la IA solo presenta lo que el sistema devuelve. Si se rompe una regla, los casos de uso responden con un error que dice el motivo (por ejemplo, hardship_required).

Casos de uso

ProposeArrangement	Arma la oferta N (1 = todo de una, 2 = 2 cuotas...). Desde la 4 exige las Hardship Questions. first_due es opcional (hoy por defecto). Devuelve null si no quedan ofertas.
Entrada (JSON)	**Salida (JSON)**

<pre>{
  "call_id": "7c1e4b2a-5d3f-4e8a-9b61-0f2d3c4a5b6e",
  "account_external_id": "ACC-T001",
  "offer_number": 2,
  "first_due": "2026-11-13"
}</pre>
	<pre>{
	  "type": "plan",
	  "total_amount_cents": 48500,
	  "payments": [
	  {
	  "sequence": 1,
	  "amount_cents": 24250,
	  "due_date": "2026-11-13"
	  },
	  {
	  "sequence": 2,
	  "amount_cents": 24250,
	  "due_date": "2026-12-13"
	  }
	  ]
	}</pre>

ProposeNextOffer	El sistema elige la oferta más rápida que el deudor todavía no rechazó y la registra. Devuelve null si ya rechazó todas.
Entrada (JSON)	**Salida (JSON)**

<pre>{
  "call_id": "7c1e4b2a-5d3f-4e8a-9b61-0f2d3c4a5b6e",
  "account_external_id": "ACC-T001",
  "first_due": null
}</pre>
	<pre>{
	  "proposal_id": "P3c9e1a7b",
	  "offer_number": 1,
	  "proposal": {
	  "type": "full",
	  "total_amount_cents": 48500,
	  "payments": [
	  {
	  "sequence": 1,
	  "amount_cents": 48500,
	  "due_date": "2026-11-09"
	  }
	  ]
	  }
	}</pre>

ProposePartialPayment	Parcial con el monto que dijo el deudor; el resto va a 30 días si remainder_due es null. Menos del 10% exige Hardship y que el sistema tenga registradas todas las ofertas rechazadas.
Entrada (JSON)	**Salida (JSON)**

<pre>{
  "call_id": "7c1e4b2a-5d3f-4e8a-9b61-0f2d3c4a5b6e",
  "account_external_id": "ACC-T001",
  "amount_cents": 10000,
  "first_due": "2026-11-12",
  "remainder_due": null
}</pre>
	<pre>{
	  "proposal_id": "P8d21f04c",
	  "offer_number": null,
	  "proposal": {
	  "type": "partial",
	  "total_amount_cents": 48500,
	  "payments": [
	  {
	  "sequence": 1,
	  "amount_cents": 10000,
	  "due_date": "2026-11-12"
	  },
	  {
	  "sequence": 2,
	  "amount_cents": 38500,
	  "due_date": "2026-12-12"
	  }
	  ]
	  }
	}</pre>

RecordOfferResponse	Si accepted es true, crea el acuerdo con la propuesta guardada (nunca con montos que envíe la IA) y la cuenta pasa a PTP. Si es false, registra el rechazo y arrangement_id va null.
Entrada (JSON)	**Salida (JSON)**

<pre>{
  "call_id": "7c1e4b2a-5d3f-4e8a-9b61-0f2d3c4a5b6e",
  "proposal_id": "P3c9e1a7b",
  "accepted": true
}</pre>
	<pre>{
	  "arrangement_id":
	"e4f5a6b7-c8d9-4e0f-8a1b-2c3d4e5f6a7b"
	}</pre>

CreateArrangement	Revalida la propuesta contra el saldo actual, guarda el acuerdo y sus pagos y pasa la cuenta a PTP.
Entrada (JSON)	**Salida (JSON)**

<pre>{
  "call_id": "7c1e4b2a-5d3f-4e8a-9b61-0f2d3c4a5b6e",
  "account_external_id": "ACC-T001",
  "proposal": {
  "type": "plan",
  "total_amount_cents": 48500,
  "payments": [
  {
  "sequence": 1,
  "amount_cents": 24250,
  "due_date": "2026-11-13"
  },
  {
  "sequence": 2,
  "amount_cents": 24250,
  "due_date": "2026-12-13"
  }
  ]
  }
}</pre>
	<pre>{
	  "arrangement_id":
	"e4f5a6b7-c8d9-4e0f-8a1b-2c3d4e5f6a7b"
	}</pre>

Error de regla (todas las funciones de negociación)	Si se rompe una regla, en vez de la salida normal se devuelve el motivo. Ejemplo: pedir la oferta 4 sin haber hecho las Hardship Questions.
Entrada (JSON)	**Salida (JSON)**

<pre>{
  "call_id": "7c1e4b2a-5d3f-4e8a-9b61-0f2d3c4a5b6e",
  "account_external_id": "ACC-T001",
  "offer_number": 4,
  "first_due": null
}</pre>
	<pre>{
	  "error": "hardship_required"
	}</pre>

Preguntas y respuestas

Pregunta	Respuesta	Origen
¿Descuentos?	"JAMÁS... siempre se le cobra todo". El parcial no perdona el resto.	Desarrollador
Orden de las ofertas	Todo de una, luego 2 cuotas, luego 3, "siempre por lo más rapido".	Desarrollador
¿El deudor propone el plan?	No, acepta. Cuotas iguales y de frecuencia fija. Solo propone el monto de un parcial.	Desarrollador
¿Cada cuánto se paga?	"Cuotas mensuales fecha establecida".	Jefe
¿Mínimo del pago?	10%, también para la primera cuota.	Jefe
¿Menos del 10%?	"En casos muy específicos": piso de 5%, solo como último recurso.	Jefe
¿Plazo del primer pago?	Máximo 8 días ("Si, se puede pagar a 8 dias").	Jefe
¿Plazo del resto de un parcial?	"Normalmente es al mes": 30 días.	Jefe
¿Plazo máximo del plan?	1 año.	Desarrollador
¿Estado al crear el acuerdo?	PTP. RCC queda fuera del alcance.	Jefe

Pregunta	Respuesta	Origen
¿Qué pasa después de PTP?	El recordatorio lo hace un cobrador; ahí termina el agente.	Desarrollador

Supuestos vigentes

- Máximo de 10 cuotas.
- Los 30 días del resto se cuentan desde el primer pago; el resto va en un solo pago.
- Si un mes no tiene el día fijado, se usa su último día.
- Un solo acuerdo activo por cuenta.
- Todo acuerdo pasa a PTP, incluido el pago total.

Función 5: Hardship Questions

Qué hace: Guarda las respuestas sobre la situación económica del deudor para ofrecer después un plan más largo (de 4 a 10 cuotas).

Por qué: Se hacen solo cuando el deudor no puede con 3 cuotas, para encontrar un plan que sí pueda cumplir.

Casos de uso

RecordHardshipAssessment	Guarda las respuestas; se puede repetir en la llamada para completarlas. Todos los campos de answers son opcionales. duration_type: temporary o long_term.
Entrada (JSON)	**Salida (JSON)**
`{ "call_id": "7c1e4b2a-5d3f-4e8a-9b61-0f2d3c4a5b6e", "answers": { "situation_description": "Reduced hours at work", "situation_started": "in October", "duration_type": "temporary", "household_support": true, "offered_amount_cents": 2500, "notes": null, "recommended_plan": "partial" } }`	`{ "saved": true }`

Preguntas y respuestas

Pregunta	Respuesta	Origen
¿Cuándo se hacen?	Si no puede con 3 cuotas, antes de ofrecer de 4 a 10.	Desarrollador
¿Qué preguntas?	Las 5 que entregó el jefe.	Jefe
¿Traducción al inglés?	Aprobada.	Desarrollador
¿"Vender el carro" o "pedir prestado"?	Descartadas por poder verse como presión. Si hace falta preguntar más, se sigue el tono de las 5 del jefe.	Desarrollador
¿Y si sigue sin poder pagar?	Se transfiere a un agente.	Jefe
¿Cómo se registra una promesa?	Se anota, con fecha y monto en scheduled_payments.	Desarrollador

Función 6: IVR PCI (bloqueada)

Qué hace: Transferir la llamada a un IVR certificado PCI donde el deudor teclea la tarjeta, y registrar el resultado del pago.

Por qué: La IA y las grabaciones nunca deben contener datos de tarjeta (PCI DSS).

Preguntas y respuestas

Pregunta	Respuesta	Origen
¿Cómo se paga con tarjeta?	Transferencia a un IVR PCI con captura por teclado (DTMF).	Desarrollador
¿Qué proveedor?	Por elegir. Queda como bloqueante; primero se terminan las demás funciones.	Desarrollador

Pendiente

- Elegir el proveedor y saber cómo devuelve el resultado del pago. Los casos de uso se definen después.

Función 7: disputas y "no llamar"

Qué hace: Marca la cuenta en disputa o al deudor como "no llamar" y cierra la llamada. Ninguna de las dos marcas la quita el agente: solo una persona.

Por qué: Por ley de cobranza no se puede seguir cobrando una deuda disputada ni llamar a quien pidió que no.

Casos de uso

RecordDispute	Exige grabación y verificación. Marca solo esa cuenta (las demás siguen cobrables) y cierra la llamada como dispute.
Entrada (JSON)	**Salida (JSON)**

<pre>{
  "call_id": "7c1e4b2a-5d3f-4e8a-9b61-0f2d3c4a5b6e",
  "account_external_id": "ACC-T001",
  "transcript": "Agent: ... Debtor: ..."
}</pre>
	<pre>{
	  "summary": "Jane Carter said she already paid the bounced amount. Account marked as disputed for review by a representative."
	}</pre>

MarkDoNotCall	Marca al deudor (todas sus cuentas) y cierra la llamada como do_not_call.
Entrada (JSON)	**Salida (JSON)**

<pre>{
  "call_id": "7c1e4b2a-5d3f-4e8a-9b61-0f2d3c4a5b6e",
  "transcript": "Agent: ... Debtor: ..."
}</pre>
	<pre>{
	  "summary": "Jane Carter asked not to be called again. Marked as do not call."
	}</pre>

Preguntas y respuestas

Pregunta	Respuesta	Origen
¿"Yo sí pagué" o "fue error del banco" cuenta como disputa?	Sí: se marca, se cierra como dispute y pasa a una persona.	Desarrollador

Supuestos vigentes

- Una disputa o "no llamar" impide cobrar.
- En entrantes, "no llamar" exige verificación; en salientes no.
- Una disputa no cancela un acuerdo que ya está en PTP.
- Sin grabación aceptada, "no llamar" se guarda pero la llamada se cierra como recording_refused.

Paso 8: conversación con Claude (en construcción)

Qué hace: Chat en la terminal donde una persona escribe simulando ser el deudor y Claude responde como el agente, usando los casos de uso anteriores como herramientas. Es el mismo cerebro que tendrá la llamada de voz.

Por qué: Probar el flujo completo sin gastar en voz ni montar endpoints. Claude solo conversa; cada herramienta llama a un caso de uso que aplica las reglas.

Casos de uso

Iniciar conversación (diseño)	Abre la llamada. Entrante: con el teléfono. Saliente: con la cuenta del job.
Entrada (JSON)	**Salida (JSON)**

{
  "direction": "inbound",
  "caller_phone": "+13055550001",
  "account_external_id": null
}
	{
	  "call_id": "7c1e4b2a-5d3f-4e8a-9b61-0f2d3c4a5b6e",
	  "agent_text": "Hi, thanks for calling. This call is recorded for quality and compliance purposes. Is that okay with you?",
	  "call_ended": false,
	  "outcome": null
	}

Turno del deudor (diseño)	Envía lo que dijo el deudor; el backend ejecuta las herramientas que pida Claude y devuelve su respuesta.
Entrada (JSON)	**Salida (JSON)**

{
  "call_id": "7c1e4b2a-5d3f-4e8a-9b61-0f2d3c4a5b6e",
  "debtor_text": "Okay, I can do two payments."
}
	{
	  "agent_text": "Great. That's two monthly payments of two hundred forty-two dollars and fifty cents, starting November 13. Shall I set that up?",
	  "call_ended": false,
	  "outcome": null
	}

Herramienta de Claude, ejemplo (diseño)	Herramientas: record_recording_consent, verify_identity, get_account_details, propose_offer, record_offer_response, propose_partial_payment, record_hardship_answers, record_dispute, mark_do_not_call, transfer_to_human y end_call.
Entrada (JSON)	**Salida (JSON)**

{
  "tool": "propose_offer",
  "input": {
  "account_ref": "ACC-T001",
  "first_payment_date": "2026-11-13"
  }
}
	{
	  "proposal_id": "P5e7a9c2d",
	  "offer_number": 2,
	  "proposal": {
	  "type": "plan",
	  "total_amount_cents": 48500,
	  "payments": [
	  {
	  "sequence": 1,
	  "amount_cents": 24250,
	  "due_date": "2026-11-13"
	  },
	  {
	  "sequence": 2,
	  "amount_cents": 24250,
	  "due_date": "2026-12-13"
	  }
	  ]
	  }
	}

Preguntas y respuestas

Pregunta	Respuesta	Origen
¿Qué modelo conversa?	Claude Haiku 5.5, con Claude Sonnet 5.5 de respaldo.	Desarrollador
¿Aviso legal de cobranza?	Sí, justo después de verificar la identidad ("This is an attempt to collect a debt...").	Desarrollador
¿Herramientas nuevas y quitar all_offers_rejected?	Aprobado.	Desarrollador

Pendiente

- Terminar el código y sus pruebas.
- Probar con el modelo real (falta ANTHROPIC_API_KEY).

6. Proveedores, bloqueantes y pendientes

Proveedores que necesita el agente

Servicios externos que hacen falta para que el agente funcione en una llamada real. En cada uno se eligió la opción más económica que cumple con lo que pide una llamada en vivo (baja demora y certificación PCI donde aplica). Todos quedan detrás de una interfaz: cambiar de proveedor solo cambia la implementación.

Base del cálculo: 2.000 llamadas diarias × 30 días = 60.000 llamadas al mes, de 4 minutos en promedio = 240.000 minutos al mes. Precios de lista en dólares, pago por uso, consultados el 10 de noviembre de 2026.

Para qué	Proveedor	Estado	Costo mensual (USD)	Por qué se necesita
Conversación con el deudor (el agente)	Anthropic: Claude Haiku 5.5	**Elegido**	**~330** USD 0,10 / 0,50 por millón de tokens de entrada / salida; con caché del prompt	Es el cerebro de la llamada: entiende al deudor, responde y pide las herramientas del backend. Haiku es el más rápido y barato, y en voz la rapidez importa.
Resumen de cada llamada	Anthropic: Claude Haiku 5.5	**Elegido**	**~24** ~USD 0,0004 por resumen	Resume la transcripción en inglés para el equipo.
Respaldo de la IA	Anthropic: Claude Sonnet 5.5	**Elegido**	**~60** USD 2 / 10 por millón de tokens; solo si Haiku falla (~1% de las llamadas)	Si Haiku falla o rechaza, responde Sonnet y la llamada no se cae.
Telefonía, grabación y números	Telnyx Voice API	Recomendado, sin aprobar	**~2.794** USD 0,0116 por minuto (control 0,002 + línea 0,0041 + audio en vivo 0,0035 + grabación 0,002) y 10 números a USD 1	Da los números, conecta la llamada, graba (obligatorio) y envía el audio en vivo al agente. Twilio costaría ~USD 4.260 por lo mismo.
Pago con tarjeta (IVR PCI)	Telnyx Pay over Voice	**Recomendado, sin aprobar. Bloquea la Función 6.**	**~1.200** USD 0,20 por pago (precio de Twilio Pay; el de Telnyx está por confirmar), 6.000 pagos al mes	El deudor teclea la tarjeta en un sistema certificado PCI DSS; la IA y las grabaciones nunca ven el número. Al ser el mismo proveedor de la telefonía, no hace falta transferir a otra empresa.
Voz a texto (STT)	Deepgram Nova-3 (streaming)	Recomendado, sin aprobar	**~1.848** USD 0,0077 por minuto	Convierte lo que dice el deudor en texto para Claude, en tiempo real.
Texto a voz (TTS)	Deepgram Aura-2	Recomendado, sin aprobar	**~2.700** USD 30 por millón de caracteres; ~1.500 caracteres por llamada	Convierte la respuesta de Claude en voz natural en inglés. Más barato que Cartesia (~USD 3.400) y ElevenLabs (~USD 3.600), y es el mismo proveedor de STT.
Orquestación de voz	Pipecat (código abierto)	Recomendado, sin aprobar	**0** Sin licencia; corre en los servidores	Une telefonía, STT, Claude y TTS, y maneja turnos e interrupciones.

Para qué	Proveedor	Estado	Costo mensual (USD)	Por qué se necesita
Servidores y base de datos	AWS, región este de EE. UU. (Fargate ARM + PostgreSQL)	Recomendado, sin aprobar	**~300** Estimado: 4 contenedores de voz de 2 vCPU, 1 de backend, base de datos y balanceador	Donde corren el backend y la voz, cerca de los deudores para tener menos demora. Si se usa la base real de la empresa, la base no suma costo.
Total mensual estimado			**~USD 9.256**	~USD 309 diarios, ~USD 0,15 por llamada, ~USD 0,04 por minuto.

Supuestos del costo

- Los USD 24 de Haiku son solo los resúmenes. Que Haiku converse en la llamada cuesta más (~USD 330), porque en cada turno vuelve a leer las instrucciones y lo que va de la llamada; con caché del prompt esa relectura cuesta la décima parte.
- Conversación: ~20 pedidos al modelo por llamada, ~6.500 tokens de entrada y ~300 de salida por pedido. Sin caché costaría ~USD 960 al mes.
- Llamadas mitad entrantes y mitad salientes. Si todas fueran salientes, la telefonía sube ~USD 220.
- Pagos con tarjeta en el 10% de las llamadas. Las comisiones del procesador de pagos (Stripe u otro) no están incluidas: se cobran sobre el dinero recaudado.
- Voz a texto con la tarifa normal de Deepgram; con la promoción actual (USD 0,0048 por minuto) bajaría a ~USD 1.152.
- Si en la prueba suena bien Deepgram Aura-1 (USD 15 por millón de caracteres), el texto a voz baja a ~USD 1.350.
- Son precios de lista. Con el volumen de 2.000 llamadas diarias se pueden negociar descuentos con Telnyx y Deepgram.

Precios de referencia: twilio.com/voice/pricing/us, telnyx.com/pricing/call-control, twilio.com/en-us/voice/pay-connectors/pricing, deepgram.com/pricing, aws.amazon.com/fargate/pricing y la tabla de precios de Anthropic.

Bloqueantes y pendientes

Tema	Impacto
Aprobar Telnyx Pay over Voice y confirmar su precio por pago	**Bloquea la Función 6.**
Aprobar los proveedores de telefonía, voz y servidores	No detienen el desarrollo; se necesitan antes de pasar del chat de prueba a llamadas reales.
ANTHROPIC_API_KEY	Hace falta para probar el resumen y la conversación con el modelo real.
Base de datos real y cómo entrega el job sus resultados	No detienen el desarrollo; se necesitan antes de conectar con el sistema real.
Fila nueva o actualizar el registro del deudor	Por definir.
Límite de 7 llamadas en 7 días (Reg F) entre agente y cobradores	Falta un abogado.
Revisión legal del guion y de los avisos	Pendiente antes del piloto.