Agente de voz de cobranza NSF

Informe de las pruebas simuladas del agente

Errores, observaciones consolidadas y riesgos del modelo Claude Haiku 5.5

11 de noviembre de 2026

Dato	Detalle
Repositorio	github.com/CristopherBuitrago/agent_caller (rama main)
Detalle de cada prueba	docs/notas_simulacion_2026-11-11.md y docs/simulacion_2 a 7_*.md
Datos usados	Base PostgreSQL con datos simulados. Deudora de prueba: Jane Carter (TEST-001), cuenta ACC-T001 con Lakeside Auto Finance, saldo USD 485
Estado del backend	228 pruebas automáticas pasan

1. Cómo se hicieron las pruebas

No hay **ANTHROPIC_API_KEY**, así que el agente no pudo probarse con el modelo de producción (Claude Haiku 5.5). En su lugar, **Claude Opus 5.5** (el asistente de desarrollo) hizo de agente: siguió el prompt real del agente y llamó las **mismas 11 herramientas** del backend contra la base de prueba. El desarrollador hizo de deudor. Las reglas, las validaciones y lo guardado en la base son reales.

Se simularon 7 llamadas, numeradas así en el resto del informe:

#	Escenario	Llamada
1	Negociación con pago parcial y pedido de descuento	Saliente
2	La deudora llama tras un SMS de pago rebotado	Entrante
3	Contesta el esposo de la deudora	Saliente
4	Disputa: "ya pagué, fue error del banco"	Saliente
5	Hardship Questions completas	Entrante
6	Verificación fallida dos veces	Saliente
7	Deudora molesta que pide no ser llamada y amenaza	Saliente

Resultado general: el backend aplicó sus reglas en las 7 llamadas (ningún descuento guardado, ninguna fecha fuera de rango, nunca se habló de la deuda sin verificar) y ninguna herramienta falló. Salieron **2 errores de código** y **48 observaciones distintas**, sin repetir (15 de negocio, 15 de backend, 11 del prompt y 7 legales), agrupadas por quién las resuelve.

Límite: Opus es el modelo más grande y razona más antes de responder. Estas pruebas validan el diseño, no el comportamiento de Haiku (ver sección 6).

2. Errores encontrados en el código

#	Error	Dónde y por qué	Consecuencia	Corrección propuesta	Criticidad
E1	Al colgar, el pedido de "no llamar" o la disputa se pueden perder (prueba 7)	agent_conversation.py, hang_up(): le dice al modelo "Call end_call", y end_call no acepta do_not_call ni dispute. Si el modelo no responde, el respaldo es callback_requested	Se vuelve a llamar a quien pidió que no lo llamen: riesgo legal de acoso	Cambiar el aviso de cuelgue para que use mark_do_not_call o record_dispute cuando corresponda, y una prueba con un modelo guionado que cuelga justo después del pedido	**Crítico**
E2	Guardar las Hardship Questions en dos pasos borra las respuestas anteriores (prueba 5)	postgres_hardship_repository.py: ON CONFLICT ... SET campo = EXCLUDED.campo pisa todos los campos, incluso con vacíos. La documentación dice que se puede repetir para completarlas	Si el agente guarda de a una respuesta, se pierden las anteriores sin que nadie lo note	Usar COALESCE para no pisar con vacíos, y una prueba que guarde en dos pasos	**Alto**

3. Observaciones de negocio: preguntas para el jefe

Son decisiones que no puede tomar el desarrollo. Están ordenadas por impacto.

#	Tema	Observación y propuesta	Pruebas
N1	Medio de pago a futuro	No hay forma definida de que el deudor pague un pago agendado: el único medio previsto es el IVR PCI durante la llamada (Función 6, bloqueada). El agente promete "payment instructions" que hoy no existen, y la deudora preguntó dos veces cómo pagaría. ¿Link por SMS, correo, débito, volver a llamar? La empresa ya tiene una campaña de SMS, así que podría usar ese proveedor	1, 2
N2	Verificación de identidad (pedido del jefe)	El jefe pidió quitar el nombre completo y que el agente lea los últimos 4 del SSN y la fecha de nacimiento para que el deudor diga sí o no. Revela datos personales a quien conteste, no verifica nada (cualquiera dice "sí") y no es posible con el diseño actual (los datos se guardan como hash). Propuesta: quitar el nombre, pero que el deudor siga diciendo los dos datos	1
N3	Saludo y aviso de grabación en salientes (pedido del desarrollador)	Se pidió que el saludo solo pregunte por el deudor y que el aviso de grabación vaya después de verificar. Propuesta intermedia, ya probada en las llamadas 4, 6 y 7: aviso cuando la persona confirma ser el deudor, antes de verificar, y sin grabar hasta su "sí"	3, 4, 6, 7
N4	Ofertas que el deudor ya descartó	El sistema obliga a ofrecer pago total, 2 y 3 cuotas en orden, aunque el deudor ya dijo que no puede pagar o que su máximo son 4 cuotas. Alarga la llamada y suena a que el agente no escucha. ¿Se mantiene, se presentan varias opciones juntas o se saltan las que superan lo que el deudor dijo poder pagar?	1, 5
N5	Cuando lo que puede pagar el deudor no alcanza	Una deudora ofreció USD 30 al mes; el plan más largo permitido (10 cuotas, 1 año) es de USD 48,50 al mes. El sistema obliga a recorrer 7 ofertas más para llegar al mismo final. ¿Saltar a 10 cuotas o a una persona, permitir planes más largos con Hardship, o dejarlo como está?	5
N6	Pago parcial con un resto imposible	Un parcial de USD 90 deja USD 395 en un solo pago a 30 días, para alguien con USD 300 al mes. ¿Se ofrecen cuotas antes de aceptar el parcial que propone el deudor? ¿El resto puede ir en cuotas?	1
N7	Acuerdos con riesgo alto de incumplirse	"I'll give it a try" se tomó como aceptación de un acuerdo que la deudora dudaba poder cumplir. ¿El agente acepta igual o insiste en otra opción?	1
N8	Fecha de la primera cuota	Las ofertas llegan con la primera cuota hoy, aunque el deudor pida tiempo (puede ser hasta en 8 días). ¿Hoy por defecto o la próxima fecha de pago del deudor?	5
N9	Seguimiento sin acuerdo	Si la llamada termina sin acuerdo (el deudor consulta con alguien, contestó un tercero, pidió que lo llamen), ¿quién vuelve a llamar y cuándo? El trabajo del agente hoy termina solo en PTP	2, 3, 5
N10	Qué pasa después de PTP	¿El deudor recibe recordatorios, por qué medio, y qué pasa si no paga en la fecha? La deudora preguntó si la seguirían llamando	2
N11	Revisión de disputas	¿Quién revisa una disputa, en cuánto tiempo y cómo se le informa el resultado al deudor? ¿Se puede consultar si un pago entró, para confirmarlo en la misma llamada?	4
N12	Deudor que no logra verificarse	En una saliente, la verdadera deudora que falla la verificación se queda sin saber por qué la llamaron ni cómo resolverlo. ¿Se le da un número de contacto, una persona o una nueva llamada?	6
N13	"No llamar" y quejas por las llamadas	¿El agente ofrece "no llamar" u otro medio (SMS, horario) cuando el deudor se queja, o solo lo marca si lo pide? Después de "no llamar", ¿la cobranza sigue por otro medio? La deuda sigue existiendo	7
N14	Deudores vulnerables y amenazas	No hay protocolo para un deudor desesperado ni para amenazas de violencia, y no hay dónde registrarlas. ¿Pasar a una persona, pausar la cobranza, avisar a un supervisor?	5, 7
N15	Proveedor de telefonía y programa de los cobradores	¿Qué proveedor usa la empresa para sus SMS? ¿Sirve para voz? ¿Qué programa usan los cobradores para recibir llamadas? De eso depende cómo se transfiere la llamada y cómo le llega el motivo al cobrador	2

4. Observaciones de backend: código y herramientas

#	Tema	Observación y propuesta	Pruebas
B1	Continuidad entre llamadas	Las Hardship Questions quedan atadas a la llamada y las ofertas rechazadas viven en memoria. Si el deudor vuelve a llamar, se repite todo. Propuesta: que las Hardship valgan por deudor un tiempo (p. ej. 30 días) y guardar las ofertas rechazadas en la base	5
B2	Devoluciones de llamada	callback_requested no guarda cuándo volver a llamar, el motivo ni el monto mencionado (p. ej. "vuelve a las 6 p. m.", "pagaría USD 30 a fin de mes")	2, 3, 5
B3	Resultados de llamada	Una llamada con acuerdo y transferencia queda solo como transferred_to_human y esconde el acuerdo. Falta un resultado para "contestó un tercero, la deudora no estaba"	2, 3
B4	Motivo de la transferencia	El motivo de transfer_to_human no se guarda: quien recibe la llamada no sabe por qué se la pasaron	2
B5	Disputas sin detalles	Solo se guarda is_disputed. Faltan fecha del pago que dice haber hecho, medio, número de confirmación y notas (tabla disputes, requiere aprobar el modelo de datos)	4
B6	Motivo del rebote	get_account_details no devuelve el motivo aunque la base tiene nsf_return_code (R01 = fondos insuficientes). Devolverlo en palabras sencillas	2
B7	Fecha límite del primer pago	propose_offer no dice hasta cuándo puede ser el primer pago (hoy + 8 días); el agente no puede ofrecerlo sin conocer la regla	5
B8	Intentos de verificación	verify_identity no dice cuántos intentos quedan; el agente no puede avisar que es el último	6
B9	Instrucciones de las herramientas (next_step)	Varias no cubren casos reales: tras rechazar un parcial manda pedir la siguiente oferta aunque el deudor dio otro monto; get_account_details manda ofrecer de inmediato; record_offer_response promete "payment instructions" y no contempla la transferencia; mark_do_not_call pide despedirse aunque el deudor ya colgó	1, 2, 7
B10	Enviar link de pago o confirmación	No hay herramienta para enviar un SMS con el link o la confirmación del acuerdo. Depende de N1	2
B11	Grabación después del "sí"	Con el saludo de N3, la telefonía debe empezar a grabar después del consentimiento. Hoy no hay una acción para eso; se agrega al integrar la telefonía	3, 4
B12	Resumen con IA de llamadas delicadas	Se genera resumen aunque solo haya hablado un tercero o alguien no verificado, y en llamadas con amenazas o insultos. Definir qué incluye el resumen y que nunca mencione la deuda si no hubo verificación	3, 6, 7
B13	Bloqueo por un impostor	Con 5 fallos en 24 horas entre varias llamadas, un impostor puede bloquear a la verdadera deudora un día. Evaluar alertas	6
B14	Plan elegido en Hardship	recommended_plan existe en la tabla, pero no en la herramienta. Debería llenarlo el sistema al crear el acuerdo	5
B15	Propuesta rechazada	Un parcial rechazado no se puede aceptar después; el agente arma otro igual. Funciona; se anota para entender el registro	1

5. Observaciones del prompt del agente y temas legales

5.1 Prompt del agente

#	Tema	Observación y propuesta	Pruebas
P1	Frases fijas al inicio	Presentarse como asistente virtual en el saludo. "I can share the reason once I confirm I'm speaking with the right person" ante "¿para qué me llaman?". "To protect your privacy" al pedir los datos	1, 2, 3
P2	Consentimiento de grabación	Si el deudor ignora la pregunta, reconocer lo que dijo y volver a preguntar. Definir qué cuenta como "sí" ("yes", "okay", "that sounds fine")	1, 2, 4
P3	Terceros	Frases fijas: "a personal business matter" y "I'm only able to speak with her directly". Nunca dejar recados ni aceptar ayuda	3
P4	Confirmar antes de cerrar	Repetir montos y fechas y esperar un "sí" limpio. Un "sí, pero con descuento" no es aceptación. Corregir siempre las cifras equivocadas del deudor (dijo USD 370 y eran USD 395)	1
P5	No inventar	Regla para lo que el agente no sabe: medios de pago, si habrá cobros automáticos, quién cobra el cargo de USD 35. Si una pregunta se repite sin respuesta, ofrecer una persona	1, 2
P6	Disputa o confusión	Definir el límite: "ya pagué" y "error del banco" son disputa; "intenté pagar, no sé qué pasó" no. Antes de registrar la disputa, preguntar fecha y número de confirmación	1, 4
P7	Queja o pedido de "no llamar"	"Me llaman todo el tiempo" es una queja; "no me llamen más" es un pedido. Ante insultos, mantener la calma sin comentarlos y, si siguen, ofrecer una persona o cerrar	7
P8	Largo de los turnos	Aviso legal y deuda en un turno y la oferta en el siguiente, salvo que el deudor ya haya planteado su situación. Montos con centavos distintos (USD 161,68 y 161,66): decir "about 162 dollars a month" y los centavos solo al confirmar	1, 2, 5
P9	Devolución de llamada	Si el deudor pide que lo llamen pero puede fijar una fecha de pago dentro de 8 días, agendar el pago	2
P10	Hardship Questions	Si la respuesta no dice claramente temporal o permanente, dejar duration_type vacío y usar notes. Adaptar la pregunta 4 ("on your next pay date") cuando el deudor dijo que no tiene trabajo	5
P11	Verificación fallida	Tras un fallo, "please double-check the numbers". Al cerrar, dar un número de contacto si el jefe lo aprueba (N12)	6

5.2 Temas legales para revisar con un abogado

#	Tema	Observación y propuesta	Pruebas
L1	Volver a llamar a quien pidió no ser llamado	Es la consecuencia del error E1. Prioritario	7
L2	Consentimiento de grabación	Florida y otros estados exigen el consentimiento de todas las partes. No grabar antes del "sí" (un tercero que contesta queda grabado sin aviso). Revisar también si una llamada sin consentimiento puede tener transcripción y resumen	3
L3	Qué se le dice a un tercero	El nombre de la empresa ("Recovery Services") delata la cobranza. Definir qué nombre se dice, a quién y en qué momento	3, 4
L4	Límite de 7 llamadas en 7 días (Reg F)	Cuentan las devoluciones de llamada, los recordatorios y las llamadas fallidas, del agente y de los cobradores. Hoy el sistema no cuenta las llamadas antes de llamar	2, 6, 7
L5	Disputas	Plazos y formato de la verificación de una deuda disputada; si basta una disputa por teléfono	4
L6	Aviso "This communication is from a debt collector"	El desarrollador pidió quitarlo por repetido; la frase no se había dicho antes en la llamada. Confirmar el texto exacto del aviso	1
L7	Deudores vulnerables	Obligaciones con deudores en situación vulnerable (pérdida de empleo, angustia)	5

6. Riesgos de Claude Haiku 5.5 vistos en las pruebas

Falta la ANTHROPIC_API_KEY. Ni Claude Haiku 5.5 ni Claude Sonnet 5.5 se han podido probar. Todo lo de esta sección es una **hipótesis** basada en lo que pasó en las 7 llamadas y en cómo suelen comportarse los modelos pequeños con poco razonamiento. Solo se confirma o descarta probando con la API.

Configuración actual

- **Claude Haiku 5.5 conversa** en todas las llamadas, con **esfuerzo bajo** (effort: low): razona poco antes de responder para que la voz sea rápida.
- **Claude Sonnet 5.5 es solo respaldo:** responde un turno únicamente si Haiku falla o rechaza. **No** entra en los turnos difíciles; esos los resuelve Haiku.

Por qué hay riesgo

En varias llamadas el agente tuvo que razonar en momentos ambiguos que el prompt no cubre. Un modelo pequeño con poco razonamiento tiende a seguir la instrucción más literal (la de la herramienta o la última frase del deudor). El backend protege montos, fechas y verificación, pero **no protege lo que el agente dice ni qué herramienta elige**.

Momentos de riesgo

Momento	Qué podría hacer Haiku con esfuerzo bajo	¿Lo protege el backend?	Mitigación	Pruebas	Criticidad
Deudor cuelga justo después de pedir "no llamar" o disputar	Seguir el aviso de cuelgue y cerrar con end_call como callback_requested	No (error E1)	Corregir el aviso de cuelgue y probarlo	7	**Crítico**
Contesta un tercero o alguien no verificado	Ser amable de más: "it's about her payment", aceptar ayuda o dejar recado	Parcial: sin verificación no consulta la cuenta, pero puede hablar	Frases fijas (P3)	3, 6	**Crítico**
Preguntas sin respuesta (medio de pago, cobros, cargo de USD 35)	Inventar: "we'll text you a link", "nothing will be charged"	No	N1 y regla P5	1, 2	**Alto**
"Sí" con condiciones o cifras equivocadas	Registrar la aceptación y no corregir; el deudor cuelga mal informado	Parcial: no se guarda ningún descuento	Regla P4	1	**Alto**
Disputa o confusión	Marcar disputa ante "no sé qué pasó", o ignorar una disputa real	No	Regla P6	1, 4	**Alto**
Queja o pedido de "no llamar"	Marcar "no llamar" ante una queja, o no marcarlo ante un pedido	No	Regla P7	7	**Alto**
Guardar las Hardship de a una	Guardar después de cada respuesta, que es lo natural	No (error E2)	Corregir el repositorio	5	**Alto**
Seguir la instrucción de la herramienta al pie de la letra	Ofrecer de inmediato, prometer "payment instructions", despedirse de una línea muerta	No	Corregir los next_step (B9)	1, 2, 7	**Medio**

Momento	Qué podría hacer Haiku con esfuerzo bajo	¿Lo protege el backend?	Mitigación	Pruebas	Criticidad
Aceptación tibia de un acuerdo difícil	Aceptar "I'll give it a try" sin más	No	Decisión N7	1	**Medio**
Clasificar y adaptar las Hardship Questions	Forzar temporary o long_term; leer la pregunta 4 tal cual a alguien sin trabajo	No	Regla P10	5	**Medio**
Turnos largos y montos con centavos	Leer cifras exactas largas; turnos que no caben en voz	No aplica	Regla P8	1, 2, 5	**Bajo**
Avanzar sin consentimiento de grabación	Seguir la conversación sin el "sí"	Sí: las herramientas devuelven error	Regla P2	1, 2	**Bajo**

Opciones y costo aproximado

Con 800 llamadas diarias. Precios por millón de tokens: Haiku 5.5, USD 0,10 de entrada y USD 0,50 de salida; Sonnet 5.5, USD 2 y USD 10 (unas 20 veces más). El resto del costo mensual (telefonía, voz, servidores), unos USD 3.650, no cambia con el modelo.

Opción	Cómo funciona	Costo de la conversación (USD/mes)	Ventajas	Riesgos
A. Haiku con esfuerzo bajo (actual)	Todo lo responde Haiku; Sonnet solo si Haiku falla	~132	Lo más barato y rápido	Los momentos de la tabla dependen solo del prompt
B. Haiku con esfuerzo medio	Haiku razona más en cada turno	Algo más que A	Mejor juicio sin cambiar de modelo	Más demora por turno: hay que medirla en voz
C. Haiku y Sonnet en momentos difíciles	Sonnet solo en turnos marcados: negociación, disputa, terceros	Entre A y D	Juicio de Sonnet donde importa	Más complejo; Sonnet tarda más; se pierde la caché
D. Sonnet en todo	Sonnet conversa siempre	~2.640 (unas 20 veces A)	El mejor juicio	Unos USD 2.500 más al mes y más demora en voz

Recomendación

- Corregir los errores E1 y E2 y reforzar el prompt con las observaciones de la sección 5. Reduce el riesgo con cualquier modelo y no cuesta más por llamada.
- **Apenas haya API key**, armar unos 20 casos difíciles con los momentos de la tabla y correrlos con Haiku (menos de USD 1) y con Sonnet (unos pocos dólares).
- Decidir con datos: si Haiku con esfuerzo bajo falla, probar primero la opción B y luego la C, antes de D. Medir también la demora por turno.

7. Siguientes pasos

- Corregir los errores E1 y E2, cada uno con su prueba automática.
- Aplicar las observaciones de backend (sección 4) y del prompt (sección 5.1).
- Llevar al jefe las preguntas de negocio (sección 3).
- Llevar los temas legales (sección 5.2) a un abogado antes del piloto.

- Conseguir la ANTHROPIC_API_KEY y probar Haiku y Sonnet con los casos difíciles de la sección 6.