# Agente de voz de cobranza NSF

Informe de las 7 pruebas simuladas del agente

Resultados, comportamiento del deudor, brechas, errores y observaciones,
y criticidad del modelo Claude Haiku 5.5 frente a Claude Sonnet 5.5

11 de noviembre de 2026

| Dato | Detalle |
|---|---|
| **Repositorio** | github.com/CristopherBuitrago/agent_caller (rama main) |
| **Detalle de cada prueba** | docs/notas_simulacion_2026-11-11.md y docs/simulacion_2 a 7_*.md |
| **Datos usados** | Base PostgreSQL con datos simulados. Deudora de prueba: Jane Carter (TEST-001), cuenta ACC-T001 con Lakeside Auto Finance, saldo USD 485 (pago devuelto de USD 450 + cargo de USD 35 del 2026-10-10) |
| **Estado del backend** | 228 pruebas automáticas pasan |

# 1. Cómo se hicieron las pruebas

No hay **ANTHROPIC_API_KEY**, así que el agente no pudo probarse con el modelo de producción (Claude Haiku 5.5). En su lugar:

- **Claude Opus 5.5** (el asistente de desarrollo) hizo de agente: siguió el prompt real del agente (*agent_system_prompt.md*) y llamó las **mismas 11 herramientas** del backend contra la base PostgreSQL de prueba, a través de un simulador.
- **El desarrollador** hizo de deudor (o de la persona que contesta), escribiendo en inglés.
- Cada respuesta del backend es real: reglas de negocio, validaciones y lo que queda guardado en la base. Al terminar cada prueba se revisó la base con una consulta y luego se limpiaron los datos de prueba.

**Límite importante:** Opus es el modelo más grande de la familia y razona más antes de responder. Estas pruebas validan el **diseño** (prompt, herramientas y reglas del backend), **no** el comportamiento de Haiku. La sección 4 explica dónde Haiku podría comportarse distinto.

### Cómo se clasifican las observaciones

| Etiqueta | Quién lo resuelve |
|---|---|
| **Prompt** | Cambio en las instrucciones del agente |
| **Backend** | Cambio en el código o en las herramientas |
| **Negocio** | Lo decide el jefe |
| **Legal** | Lo debe revisar un abogado |
| **Error** | Falla del código encontrada en la prueba |

# 2. Resumen de las 7 pruebas

| # | Escenario | Llamada | Cómo terminó | Guardado en la base | Obs. |
|---|---|---|---|---|---|
| **1** | Negociación con pago parcial y pedido de descuento | Saliente | Acuerdo: USD 90 hoy y USD 395 el 2026-12-11 | Cuenta en PTP, acuerdo partial, arrangement_made | 16 |
| **2** | La deudora llama tras un SMS de pago rebotado | Entrante | Pago total agendado para mañana y transferencia a una persona | Cuenta en PTP, acuerdo full, transferred_to_human | 14 |
| **3** | Contesta el esposo de la deudora | Saliente | No se reveló la deuda; se cerró para volver a llamar | callback_requested, sin verificación | 7 |
| **4** | Disputa: "ya pagué, fue error del banco" | Saliente | Cuenta marcada en disputa, sin pedir pago | is_disputed = true, outcome dispute | 8 |
| **5** | Hardship Questions completas | Entrante | Sin acuerdo: la deudora consulta con su esposo | Respuestas de Hardship guardadas, callback_requested | 14 |
| **6** | Verificación fallida dos veces | Saliente | Cierre sin revelar la deuda | verification_failed, 2 intentos | 7 |
| **7** | Deudora molesta que pide no ser llamada y amenaza | Saliente | Marca de "no llamar" guardada | do_not_call = true, outcome do_not_call | 10 |

### Resultado general

- **El backend aplicó sus reglas en las 7 pruebas:** ningún descuento quedó guardado, ninguna fecha fuera de rango, nunca se habló de la deuda sin verificar identidad, y ninguna herramienta falló.
- **Unas 76 observaciones** en total, muchas repetidas entre pruebas.
- **2 problemas en el código** (sección 3): uno borra datos y otro puede hacer que se vuelva a llamar a quien pidió que no lo llamen.

- **Los huecos más grandes son de negocio:** cómo paga el deudor un pago a futuro, qué se le ofrece a quien no puede pagar ni 10 cuotas, y qué pasa después de una disputa o de "no llamar".

## 3. Errores encontrados en el código

| # | Error | Dónde y por qué | Consecuencia | Corrección propuesta | Criticidad |
|---|---|---|---|---|---|
| **E1** | Al colgar, el pedido de "no llamar" o la disputa se pueden perder (prueba 7) | agent_conversation.py, hang_up(): le dice al modelo "Call end_call", y end_call no acepta do_not_call ni dispute. Si el modelo no responde, el respaldo es callback_requested | Se vuelve a llamar a quien pidió que no lo llamen: riesgo legal de acoso | Cambiar el aviso de cuelgue para que use mark_do_not_call o record_dispute cuando corresponda, y una prueba con un modelo guionado que cuelga justo después del pedido | **Crítico** |
| **E2** | Guardar las Hardship Questions en dos pasos borra las respuestas anteriores (prueba 5) | postgres_hardship_repository.py: ON CONFLICT ... SET campo = EXCLUDED.campo pisa todos los campos, incluso con vacíos. La documentación dice que se puede repetir para completarlas | Si el agente guarda de a una respuesta, se pierden las anteriores sin que nadie lo note | Usar COALESCE para no pisar con vacíos, y una prueba que guarde en dos pasos | **Alto** |

# Prueba 1: negociación con pago parcial y pedido de descuento

Detalle completo: *docs/notas_simulacion_2026-11-11.md*

### Qué se hizo

Llamada saliente a Jane Carter (al principio se abrió una entrante por error y se cerró). Verificación con un fallo y luego correcta; aviso legal; ofertas en orden; pagos parciales propuestos por la deudora; cierre con acuerdo.

### Cómo actuó el deudor

- Preguntó quién llamaba antes de aceptar la grabación y dijo no saber por qué la llamaban.
- Se equivocó en el SSN (1324) en el primer intento.
- Dijo que intentó pagar ese día y no sabe qué pasó; pidió pagar solo los USD 450 y preguntó por qué le cobran USD 35.
- Contó que tiene USD 300 para todo el mes; ofreció USD 90; pidió 4 cuotas; volvió a los USD 90 con el resto el mes siguiente.
- Pidió un descuento sobre "los 370 que quedan" (el resto real era USD 395).
- Aceptó con duda: "I'll give it a try".

### Resultado

Acuerdo parcial: USD 90 el 2026-11-11 y USD 395 el 2026-12-11. Cuenta en PTP, llamada arrangement_made con 2 intentos de verificación.

### Brechas, errores y observaciones

| Tipo | Observación |
|---|---|
| **Negocio** | Pedido del jefe (J1): verificar sin nombre completo, leyendo SSN y fecha para que el deudor diga sí o no. Revela datos personales a quien conteste, no verifica nada y no es posible con el diseño actual (datos guardados como hash). Propuesta: quitar el nombre, pero que el deudor siga diciendo los datos |
| **Legal** | Pedido del desarrollador (D1): quitar "This communication is from a debt collector". La frase no se había dicho antes en la llamada; lo debe confirmar el abogado |
| **Prompt** | Presentarse como asistente virtual desde el saludo |
| **Prompt** | Frase fija para "¿por qué me llaman?" antes de verificar |
| **Prompt** | Saludo saliente: preguntar por el deudor y pedir la grabación en una sola frase |
| **Prompt** | Turno demasiado largo tras verificar: aviso + deuda + oferta |
| **Prompt** | Cómo explicar el cargo de USD 35 sin inventar quién lo cobra |
| **Prompt** | Límite entre disputa y confusión ("I tried to pay, I'm not sure what happened") |
| **Negocio** | Un parcial propuesto por el deudor deja un resto imposible (USD 395 en un pago para alguien con USD 300 al mes). ¿Cuotas primero? ¿El resto puede ir en cuotas? |
| **Backend** | Tras rechazar un parcial, el next_step manda pedir la siguiente oferta aunque el deudor ya dio otro monto |
| **Negocio** | Recorrer 2 y 3 cuotas una por una aunque el deudor ya dijo su límite (4 cuotas) |
| **Backend** | Un parcial rechazado no se puede aceptar después; se arma otro igual |
| **Prompt** | Repetir montos y fechas y esperar un "sí" limpio antes de crear el acuerdo |
| **Prompt** | "Sí, pero con descuento" no es un sí; corregir cifras equivocadas del deudor |
| **Negocio** | Aceptación tibia de un acuerdo con riesgo alto de incumplirse |
| **Negocio** | "You will receive the payment instructions": ese envío no existe hoy |

# Prueba 2: llamada entrante tras un SMS de pago rebotado

Detalle completo: *docs/simulacion_2_entrante_2026-11-11.md*

### Qué se hizo

La deudora llama porque vio un mensaje de texto. Grabación, verificación al primer intento, aviso legal y deuda, pago total agendado para el día siguiente y transferencia a una persona para saber cómo pagar.

### Cómo actuó el deudor

- Antes de aceptar la grabación preguntó por qué rebotó el pago.
- Recordó el pago ("I had forgotten") y pidió pagar mañana, cuando le pagan, y que la llamaran.
- Preguntó cómo funcionaría, si dejarían de llamarla y si le enviarían un link de pago.
- Insistió: "¿alguien me va a llamar y me va a cobrar en la llamada?"
- Aceptó el pago para mañana y pidió que la transfirieran.

### Resultado

Pago total de USD 485 para el 2026-11-12. Cuenta en PTP, llamada transferred_to_human.

### Brechas, errores y observaciones

| Tipo | Observación |
|---|---|
| **Negocio** | Cómo paga el deudor un pago agendado (link por SMS, correo, débito, volver a llamar). Fue lo que más fricción causó |
| **Negocio** | Qué se le promete al deudor después de PTP: recordatorios, medio, qué pasa si no paga |
| **Backend** | get_account_details no devuelve el motivo del rebote (nsf_return_code R01) |
| **Backend** | callback_requested no guarda fecha ni hora para volver a llamar |
| **Backend** | El resultado transferred_to_human esconde que sí hubo acuerdo |
| **Backend** | El motivo de transfer_to_human no se guarda para quien recibe la llamada |
| **Backend** | No hay herramienta para enviar link de pago o confirmación |
| **Prompt** | Volver a pedir la grabación si el deudor la ignora; frase "To protect your privacy" |
| **Prompt** | Aviso y deuda en un turno y oferta en el siguiente; ajustar el next_step |
| **Prompt** | Si el deudor pide que lo llamen pero puede fijar fecha en 8 días, agendar el pago |
| **Prompt** | Regla sobre medios de pago no definidos para no inventar ("no se le cobrará nada", "le enviaremos un link") |
| **Prompt** | Si una pregunta se repite sin respuesta, ofrecer una persona |
| **Prompt** | next_step de record_offer_response cuando el deudor pide transferencia |
| **Legal** | Devoluciones de llamada y recordatorios cuentan para el límite de 7 en 7 días |

# Prueba 3: contesta el esposo de la deudora

Detalle completo: *docs/simulacion_3_tercero_contesta_2026-11-11.md*

### Qué se hizo

Llamada saliente a Jane Carter; contesta su esposo. El agente no revela nada de la deuda y cierra para volver a llamar.

### Cómo actuó el deudor

- El esposo preguntó quién llamaba y cómo podía ayudar.
- Ofreció ayudar "con lo que necesite" y dijo que Jane vuelve hacia las 6 p. m.

### Resultado

Llamada callback_requested, sin consentimiento ni verificación. No se reveló monto, acreedor ni motivo.

### Brechas, errores y observaciones

| Tipo | Observación |
|---|---|
| **Negocio** | Pedido del desarrollador (D2): el saludo solo pregunta por Jane y el aviso de grabación va después de verificar. Propuesta: aviso cuando la persona confirma que es Jane, antes de verificar, y no grabar hasta su "sí" |
| **Legal** | El nombre de la empresa ("Recovery Services") delata la cobranza ante un tercero |
| **Legal** | No grabar hasta que la deudora acepte (Florida exige consentimiento de todas las partes) |
| **Prompt** | Frases fijas para terceros: "a personal business matter" y "I'm only able to speak with her directly"; nunca dejar recados |
| **Backend** | Se pierde la hora que dio el tercero (6 p. m.) |
| **Backend** | Falta un resultado para "contestó un tercero, la deudora no estaba" |
| **Backend** | Qué hacer con la transcripción y el resumen de una llamada sin consentimiento |

# Prueba 4: disputa, "ya pagué, fue error del banco"

Detalle completo: *docs/simulacion_4_disputa_2026-11-11.md*

### Qué se hizo

Llamada saliente con el saludo del pedido D2. Grabación, verificación, aviso legal y deuda; la deudora disputa y la llamada se cierra sin pedir pago.

### Cómo actuó el deudor

- Confirmó ser Jane y preguntó quién llamaba y para qué.
- Al escuchar la deuda dijo: "I already paid that; it was the bank's fault, not mine."

### Resultado

Cuenta marcada en disputa (is_disputed = true), estado NSF sin cambios, llamada dispute, sin acuerdos.

### Brechas, errores y observaciones

| Tipo | Observación |
|---|---|
| **Backend** | La disputa se guarda sin detalles: fecha del pago, medio, número de confirmación |
| **Prompt** | Preguntar esos detalles antes de record_dispute, que cierra la llamada al instante |
| **Negocio** | Quién revisa la disputa, en cuánto tiempo y cómo se informa el resultado |
| **Negocio** | ¿Se puede consultar si el pago entró, para confirmarlo en la llamada? |
| **Prompt** | Qué respuestas cuentan como aceptación de la grabación |
| **Backend** | Acción para empezar a grabar después del "sí" (flujo D2) |
| **Legal** | Plazos y formato de la verificación de una deuda disputada; disputa verbal o escrita |
| **Legal** | Qué nombre de empresa se dice al identificarse y en qué momento |

# Prueba 5: Hardship Questions completas

Detalle completo: *docs/simulacion_5_hardship_2026-11-11.md*

### Qué se hizo

Llamada entrante. La deudora rechaza el pago total, 2 y 3 cuotas; el sistema exige las Hardship Questions; se hacen las 5 preguntas; se ofrecen 4 cuotas y la deudora queda en consultar.

### Cómo actuó el deudor

- Llamó para decir que no puede pagar y necesita tiempo.
- Perdió el trabajo el mes pasado; busca por LinkedIn y en persona; dijo estar desesperada.
- Su esposo ayuda un poco, pero trabaja medio tiempo.
- Ofreció USD 30 a fin de mes y luego USD 30 al mes desde fin de mes.
- Ante 4 cuotas de USD 121,25 dijo que necesita hablar primero con su esposo.

### Resultado

Sin acuerdo. Respuestas de Hardship guardadas (monto ofrecido USD 30, ayuda en el hogar, duración vacía a propósito). Llamada callback_requested.

### Brechas, errores y observaciones

| Tipo | Observación |
|---|---|
| **Error** | Guardar las Hardship Questions en dos pasos borra las respuestas anteriores (E2) |
| **Backend** | Las Hardship y las ofertas rechazadas no valen para la próxima llamada: se repite todo |
| **Backend** | propose_offer debe devolver la fecha límite del primer pago (hoy + 8 días) |
| **Backend** | recommended_plan no está en la herramienta; debería llenarlo el sistema |
| **Backend** | callback_requested sin fecha, motivo ni monto mencionado |
| **Negocio** | Si lo que ofrece el deudor no alcanza ni para 10 cuotas (USD 48,50 al mes), ¿saltar, permitir planes más largos o recorrer las 10 ofertas? |
| **Negocio** | ¿La primera cuota se ofrece hoy o en la próxima fecha de pago del deudor? |
| **Negocio** | ¿Ofrecer pago total, 2 y 3 cuotas aunque el deudor ya dijo que no puede? |
| **Negocio** | Protocolo para deudores vulnerables ("I'm desperate") |
| **Negocio** | Seguimiento cuando la llamada termina sin acuerdo |
| **Prompt** | duration_type vacío si la respuesta no es clara; adaptar la pregunta 4 a lo ya dicho |
| **Prompt** | Cuotas "iguales" con centavos distintos: cómo decirlas en voz |
| **Prompt** | Permitir la oferta en el mismo turno que la deuda si el deudor ya planteó su situación |
| **Legal** | Obligaciones con deudores en situación vulnerable |

# Prueba 6: verificación fallida dos veces

Detalle completo: *docs/simulacion_6_verificacion_fallida_2026-11-11.md*

### Qué se hizo

Llamada saliente. Quien contesta dice ser Jane, acepta la grabación y falla la verificación dos veces; la llamada se cierra sin revelar la deuda.

### Cómo actuó el deudor

- Primer intento: SSN con dos dígitos invertidos (1243 en vez de 1234).
- Segundo intento: SSN correcto, fecha de nacimiento un día corrida (March 15).

### Resultado

Llamada verification_failed con 2 intentos; grabación aceptada; identidad sin verificar.

### Brechas, errores y observaciones

| Tipo | Observación |
|---|---|
| **Backend** | verify_identity no dice cuántos intentos quedan (attempts_left) |
| **Prompt** | Tras un fallo, "please double-check the numbers" en vez de solo "repeat" |
| **Negocio** | Qué se le ofrece a la verdadera deudora que no logra verificarse: número de contacto, persona o nueva llamada |
| **Prompt** | Cierre con número de contacto, según lo que decida el jefe |
| **Backend** | Un impostor puede bloquear a la verdadera deudora 24 horas (5 fallos entre llamadas) |
| **Backend** | Resumen con IA de llamadas sin verificar: que no mencione la deuda |
| **Legal** | Las llamadas fallidas cuentan para el límite de 7 en 7 días |

# Prueba 7: deudora molesta que pide no ser llamada

Detalle completo: *docs/simulacion_7_deudor_molesto_2026-11-11.md*

### Qué se hizo

Llamada saliente. La deudora contesta molesta, se queja de las llamadas con insultos, pide que no la llamen, amenaza y cuelga. Se marca "no llamar" sin verificar (supuesto vigente en salientes).

### Cómo actuó el deudor

- Se quejó de que la llaman todo el tiempo, con insultos.
- Pidió que no la volvieran a llamar, amenazó con violencia y colgó.

### Resultado

Deudora marcada do_not_call (todas sus cuentas); llamada do_not_call; cuenta NSF sin cambios.

### Brechas, errores y observaciones

| Tipo | Observación |
|---|---|
| **Error** | Al colgar, el pedido de "no llamar" o la disputa se pueden perder (E1) |
| **Legal** | Volver a llamar a quien pidió no ser llamado |
| **Negocio** | Protocolo para amenazas de violencia y dónde se registran |
| **Negocio** | ¿Se ofrece "no llamar" u otro medio de contacto cuando el deudor se queja? |
| **Negocio** | Después de "no llamar", ¿la cobranza sigue por otro medio? |
| **Prompt** | Cómo tratar insultos sin discutir; cuándo ofrecer una persona o cerrar |
| **Prompt** | Distinguir la queja ("they keep calling me") del pedido ("don't call me again") |
| **Backend** | Cómo se resume una llamada con amenazas e insultos |
| **Prompt** | next_step de mark_do_not_call cuando el deudor ya colgó |
| **Legal** | Contar las llamadas por deudor (7 en 7 días) antes de llamar |

# 4. Criticidad de Claude Haiku 5.5 frente a Claude Sonnet 5.5

## Configuración actual

- **Claude Haiku 5.5 conversa** en todas las llamadas, con **esfuerzo bajo** (effort: low): razona poco antes de responder para que la voz sea rápida.
- **Claude Sonnet 5.5 es solo respaldo:** responde un turno únicamente si Haiku falla o rechaza. **No** se usa para los turnos difíciles; esos los resuelve Haiku.
- Ninguno de los dos se ha probado todavía: falta la ANTHROPIC_API_KEY.

## Por qué importa

En las 7 pruebas, el agente (Opus) tuvo que razonar en momentos ambiguos que el prompt no cubre: un "sí" con condiciones, una queja que parece un pedido, una pregunta sin respuesta que invita a inventar. Un modelo pequeño con poco razonamiento tiende a seguir la instrucción más literal (el next_step de la herramienta o la última frase del deudor). El backend protege los montos, las fechas y la verificación, pero **no protege lo que el agente dice ni qué herramienta elige** en estos momentos.

**Todo lo que sigue es una hipótesis**, basada en lo que se vio en las pruebas y en cómo suelen comportarse los modelos pequeños con poco razonamiento. Se confirma o descarta probando con la API.

## Momentos de riesgo encontrados en las pruebas

| Momento (prueba) | Qué podría hacer Haiku con esfuerzo bajo | ¿Lo protege el backend? | Mitigación | Criticidad |
|---|---|---|---|---|
| **Deudor cuelga justo después de pedir "no llamar" o disputar (7)** | Seguir el aviso de cuelgue y cerrar con end_call como callback_requested | No (error E1) | Corregir el aviso de cuelgue y probarlo | **Crítico** |
| **Contesta un tercero (3)** | Ser amable de más: "it's about her payment", aceptar ayuda o dejar recado | Parcial: sin verificación no puede consultar la cuenta, pero sí puede hablar | Frases fijas para terceros; casos de prueba | **Crítico** |
| **Medio de pago no definido (2)** | Inventar: "we'll text you a link" o "nothing will be charged" | No | Decidir el medio de pago; regla en el prompt | **Alto** |
| **"Sí, pero con descuento" (1)** | Registrar la aceptación; el deudor cuelga creyendo que pidió un descuento | Parcial: el acuerdo se guarda sin descuento, pero el deudor queda mal informado | Regla: un sí con condiciones no cuenta | **Alto** |
| **Disputa o confusión (1 y 4)** | Marcar disputa ante "I'm not sure what happened", o ignorar una disputa real | No | Definir el límite en el prompt; casos de prueba | **Alto** |
| **Queja o pedido de "no llamar" (7)** | Marcar "no llamar" ante una simple queja, o no marcarlo ante un pedido | No | Definir el límite en el prompt; casos de prueba | **Alto** |
| **Guardar las Hardship de a una (5)** | Guardar después de cada respuesta, que es lo natural | No (error E2: borra las anteriores) | Corregir el repositorio | **Alto** |
| **Cifras equivocadas del deudor (1)** | No corregir "los 370 que quedan" (eran USD 395) | No | Regla en el prompt | **Medio** |
| **Aceptación tibia de un acuerdo difícil (1)** | Aceptar "I'll give it a try" sin más | No | Decisión de negocio y regla en el prompt | **Medio** |

| Momento (prueba) | Qué podría hacer Haiku con esfuerzo bajo | ¿Lo protege el backend? | Mitigación | Criticidad |
|---|---|---|---|---|
| **Clasificar respuestas de Hardship (5)** | Forzar temporary o long_term cuando la respuesta no es clara | No | Dejar vacío y usar notes | **Medio** |
| **Motivo del rebote (2)** | Inventar el motivo ("insufficient funds") sin dato | No | Devolver el motivo en la herramienta | **Medio** |
| **Montos con centavos y turnos largos (1 y 5)** | Leer cifras exactas largas; turnos que no caben en voz | No aplica | Frases habladas en la herramienta | **Bajo** |
| **Avanzar sin consentimiento de grabación (1 y 2)** | Seguir la conversación sin el "sí" | Sí: sin consentimiento, las herramientas devuelven error | Regla en el prompt | **Bajo** |

## Opciones y costo aproximado

Con 800 llamadas diarias. Los precios por millón de tokens son: Haiku 5.5, USD 0,10 de entrada y USD 0,50 de salida; Sonnet 5.5, USD 2 y USD 10 (unas 20 veces más). El costo de conversar con Haiku se estimó en unos USD 132 al mes; el resto del costo mensual (telefonía, voz, servidores) es de unos USD 3.650 y no cambia con el modelo.

| Opción | Cómo funciona | Costo de la conversación (USD/mes) | Ventajas | Riesgos |
|---|---|---|---|---|
| **A. Haiku con esfuerzo bajo (actual)** | Todo lo responde Haiku; Sonnet solo si Haiku falla | ~132 | Lo más barato y rápido | Los momentos de la tabla anterior dependen solo del prompt |
| **B. Haiku con esfuerzo medio** | Haiku razona más en cada turno | Algo más que A (más tokens de salida) | Mejor juicio sin cambiar de modelo | Más demora por turno: hay que medirla en voz |
| **C. Haiku y Sonnet en los momentos difíciles** | Sonnet responde solo en turnos marcados: negociación, disputa, terceros | Entre A y D según cuántos turnos pasen a Sonnet | Juicio de Sonnet donde importa | Más complejo; Sonnet tarda más; cambiar de modelo pierde la caché |
| **D. Sonnet en todo** | Sonnet conversa siempre | ~2.640 (unas 20 veces A) | El mejor juicio | Unos USD 2.500 más al mes y más demora en voz |

## Recomendación

- **Primero corregir los errores E1 y E2 y reforzar el prompt** con las reglas de las 7 pruebas. Esto reduce el riesgo con cualquier modelo y no cuesta más por llamada.
- **Con la API key, armar un set de unos 20 casos difíciles** sacados de estas pruebas (sí con condiciones, tercero que contesta, cuelgue tras "no llamar", disputa o confusión, medio de pago) y correrlo con Haiku. Con Haiku cuesta menos de USD 1; con Sonnet, unos pocos dólares.
- **Decidir con datos:** si Haiku con esfuerzo bajo falla en esos casos, probar primero la opción B y luego la C, antes de pensar en D.
- Medir también la demora por turno: en una llamada de voz, una respuesta lenta también es un error.

# 5. Siguientes pasos

- Corregir los errores E1 y E2, cada uno con su prueba automática.
- Aplicar las observaciones de Prompt y Backend en el orden de las pruebas (1 a 7).

- Llevar al jefe las preguntas de Negocio, sin repetidas y ordenadas por importancia.
- Llevar las observaciones Legales a un abogado antes del piloto.
- Con la ANTHROPIC_API_KEY: probar Haiku y Sonnet con los casos difíciles de este informe.